

채널 상태 정보를 활용한 대규모 언어 모델 통합형 인간 행동 인식 시스템 연구

박혜진¹, 강인혁², 이솔비³, 권정혁^{3*}, 김의직^{4*}

¹한림대학교 소프트웨어학부 학사과정, ²한림대학교 융합소프트웨어학과 박사과정,

³한림대학교 스마트컴퓨팅연구소 연구교수, ⁴한림대학교 소프트웨어학부 교수

Large Language Model-Integrated Human Activity Recognition System Using Channel State Information

Hye-Jin Park¹, Inhyeok Kang², Sol-Bee Lee³, Jung-Hyok Kwon^{3*}, Eui-Jik Kim^{4*}

¹B.S. Course, Division of Software, Hallym University

²Ph.D. Course, Department of Convergence Software, Hallym University

³Research Professor, Smart Computing Laboratory, Hallym University

⁴Professor, Division of Software, Hallym University

요약 본 논문은 사물인터넷(Internet of Things, IoT) 환경에서 채널 상태 정보(Channel State Information, CSI)를 활용한 대규모 언어 모델(Large Language Model, LLM) 통합형 인간 행동 인식(Human Activity Recognition, HAR) 시스템을 제안한다. 제안 시스템은 IoT 디바이스로부터 수집된 CSI를 활용한 HAR 분석을 통해 사용자의 행동을 추론하고, 그 결과를 LLM으로 해석하여 맞춤형 피드백을 제공하는 것을 주된 목표로 한다. 제안 시스템은 CSI 기반 행동 인식 결과와 해당 행동의 지속 시간을 통합하여 프롬프트를 구성하며, 이 과정에서 현재 행동 상태 정보, 행동별 요구사항, 피드백 길이를 반영하여 LLM 출력의 정확성과 일관성을 확보한다. 생성된 프롬프트는 LLM 기반 피드백 엔진에서 처리되어 사용자 상태에 적합한 자연어 피드백으로 변환되고, 웹 기반 인터페이스를 통해 실시간으로 제공된다. 제안 시스템의 실현 가능성을 평가하기 위해, 실제 운영 환경을 모사한 실험적 구현을 수행했다. 그 결과, CSI 기반 행동 인식부터 LLM 기반 피드백 생성에 이르는 전 과정이 안정적으로 동작함을 확인하였다.

주제어 : 대규모 언어 모델, 사물인터넷, 사용자 맞춤형 피드백, 인간 행동 인식, 채널 상태 정보

Abstract This paper presents a Human Activity Recognition(HAR) system integrated with a Large Language Model(LLM) using Channel State Information(CSI) in Internet of Things(IoT) environments. The main goal of the proposed system is to infer user activity through HAR analysis using CSI collected from IoT devices and generate personalized feedback using LLM. The proposed system constructs prompts based on the HAR results and the duration of the corresponding activities. During this process, the current activity state, task-specific requirements, and desired feedback length are considered to ensure the accuracy and consistency of the LLM outputs. The generated prompt is processed by the LLM-based feedback engine and converted into natural-language feedback appropriate to the user's activity. This feedback is then provided in real time through a web interface. To evaluate the feasibility of the proposed system, we conducted an experimental implementation. The results demonstrated the reliable operation of the entire process, from CSI-based activity recognition to LLM-based feedback generation.

Key Words : Large Language Model, Internet of Things, Personalized Feedback, Human Activity Recognition, Channel State Information,

본 논문은 2025년도 교육부 및 강원특별자치도의 재원으로 강원RISE센터의 지원을 받아 수행된 지역혁신중심 대학지원체계(RISE)의 결과입니다(2025-RISE-10-009). 이 성과는 정부(과학기술정보통신부)의 재원으로 한국연구재단의 지원을 받아 수행된 연구임(RS-2021-NR062134).

*교신저자 : 김의직(ejkim32@hallym.ac.kr), 권정혁(jhwon@hallym.ac.kr)

접수일 2025년 11월 05일 수정일 2025년 12월 01일 심사완료일 2025년 12월 16일

1. 서론

인간 행동 인식(Human Activity Recognition, HAR) 기술은 데이터를 분석하여 인간의 행동을 식별하는 기술로, 특히 스마트 헬스케어 시스템에서 핵심적인 역할을 수행한다 [1, 2]. 기존 HAR 연구는 영상 기반과 착용형 센서 기반 접근에 의존했으나, 이는 프라이버시 침해 및 장치의 지속적인 착용 제약이라는 한계를 가진다 [3, 4]. 이러한 한계를 해결하기 위해 최근 연구에서는 Wi-Fi 신호의 채널 상태 정보(Channel State Information, CSI)를 활용한 HAR가 주목받고 있다 [5, 6].

CSI는 무선 신호가 사람의 움직임과 자세 변화에 따라 달라지는 패턴을 반영한다. 따라서, 별도의 착용 장치 없이도 높은 인식 정확도와 견고성을 제공한다 [7, 8]. 특히, CSI 데이터를 딥러닝 모델로 분석하는 방식은 높은 인식 성능을 입증하고 있다. 그러나 대부분의 기존 연구는 행동 인식 정확도 향상에만 초점을 맞추고 있으며, 인식 결과를 활용해 사용자에게 실질적인 피드백을 제공하는 연구는 여전히 제한적이다.

이러한 한계를 극복하기 위해 HAR 시스템에 대규모 언어 모델(Large Language Model, LLM)을 적용하는 시도가 이루어지고 있다. LLM은 HAR과 관련된 텍스트 데이터로부터 행동 유형, 환경 조건, 행동 간 상호 관계 등을 내재적으로 학습한다. 따라서 LLM을 HAR 시스템에 결합하면, 모델이 탐지한 행동 결과를 자연어 형태로 설명하거나, 인식 결과의 의미를 상황적으로 해석할 수 있다 [9]. 즉, HAR 시스템의 행동 인식 결과로부터 사용자의 행동 패턴을 분석하고, 상황에 적합한 피드백이나 조언을 자연어 형태로 제공하는 것이 가능하다.

이러한 LLM 도입의 필요성에도 불구하고, LLM과 HAR의 통합을 직접적으로 다룬 연구는 아직 제한적이다. 다만, 최근의 IoT-LLM 통합 연구들은 센서 데이터의 의미적 해석과 자연어 기반 피드백 생성이라는 측면에서 HAR 응용에 적용 가능한 방법론적 근거를 제공한다. Kashyap et al.은 포즈 추정 기반 정보를 LLM과 연계해 행동의 의미를 설명하려는 접근을 제안하였고, Dong et al.은 LLM이 시계열 센서 데이터에서 이상 패턴을 탐지하고 추론할 수 있음을 실험적으로 보였다 [10, 11]. 또한 IoT-LLM 및 SensorLLM과 같은 프레임워크 연구들은 LLM이 다양한 센서 입력을 통합하여 상황에 맞는 설명이나 맞춤형 피드백을 생성할 수 있음을 보여주었다 [12, 13]. 그러나 기존 연구는 IoT 시스템에 LLM을 통합하기 위한 개념적, 이론적 접근에 주로 집중

되어 있어, 현실 시스템의 제약 조건 하에서 이를 직접 적용하고 구현하는 데 실질적인 어려움이 따른다. 따라서, 시스템의 목적과 구조를 고려한 LLM 통합의 실증적이며 실용적인 연구가 절실히 요구된다.

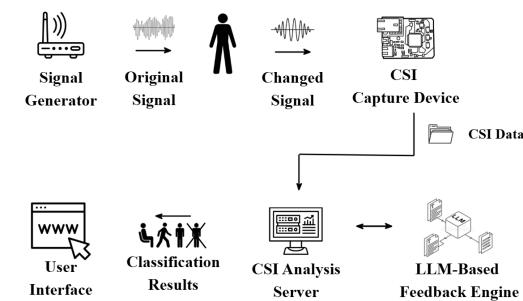
본 논문에서는 개념적·이론적 수준에 머물렀던 기존 연구의 한계를 극복하기 위해, CSI를 활용한 LLM 통합형 HAR 시스템을 설계하고, 실험적 구현을 통해 실제 운용 환경에서의 적용 가능성을 확인한다. 제안 시스템은 CSI 데이터를 활용하여 사용자의 행동을 추론하고, 그 결과를 기반으로 맞춤형 피드백을 생성하도록 구성한다. 피드백 제공 과정에서 HAR 모듈과 외부 LLM 기반 피드백 엔진은 모듈화된 인터페이스를 통해 연동된다. HAR 분석 결과는 정해진 규칙에 따라 프롬프트로 변환되며, 이는 표준화된 텍스트 구조로 LLM 기반 피드백 엔진에 전달된다. LLM 기반 피드백 엔진은 전달받은 정보를 바탕으로 맥락적 추론을 수행하고, 사용자의 상태에 적합한 자연어 피드백을 생성한다. 제안 시스템의 실효성을 검증하기 위해, 오픈소스 및 실측 데이터를 활용한 실험적 구현을 수행했다. 이를 통해 CSI 수집부터 행동 추론, LLM 기반 피드백 생성 및 제공에 이르는 전체 절차가 실제 환경에서 일관되게 동작함을 확인하였다.

본 논문은 다음과 같이 구성된다. 2장에서는 시스템 모델에 관해 소개하고, 3장에서는 LLM 기반 피드백 제공 절차를 자세히 설명한다. 4장에서는 시스템 구현 및 동작 검증 결과에 관해 기술한다. 마지막으로 5장에서는 본 연구의 결론을 맺는다.

2. 시스템 모델

본 장에서는 CSI를 활용한 LLM 통합형 HAR 시스템의 구성요소와 그 역할에 관해 기술한다. [Fig. 1]과 같이, HAR 시스템은 신호 발생기(Signal Generator), CSI 캡처기(CSI Capture Device), CSI 분석 서버(CSI Analysis Server), 사용자 인터페이스(User Interface), 그리고 외부의 LLM 기반 피드백 엔진(LLM-based Feedback Engine)으로 구성된다.

신호 발생기는 Wi-Fi 기반의 Orthogonal Frequency Division Multiplexing(OFDM) 신호를 연속적으로 발생시킨다. OFDM 신호는 다수의 직교 부반송파로 구성되며, 각 부반송파의 특성은 사용자의 위치 및 움직임에 따른 무선 채널 변화에 의해 변형된다.



[Fig. 1] LLM-Integrated HAR System

CSI 캡처기는 수신된 OFDM 신호로부터 개별 부반송파에 대한 CSI 데이터를 생성하고, 이를 파일 형태(즉, pcap 파일)로 저장한다. 이후 해당 파일을 CSI 분석 서버로 전달한다. 본 논문에서는 Single-Input Single-Output (SISO) 기반의 HAR 시스템을 가정한다. 따라서, 하나의 파일 내 포함되는 각 부반송파에 대한 CSI 데이터의 집합(H)은 식(1)과 같이 표현된다.

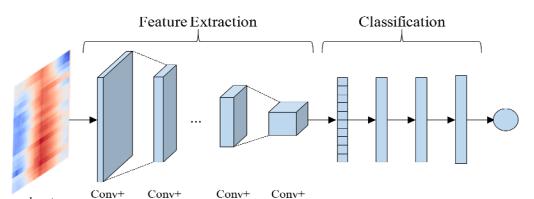
$$H = [h(1), h(2), \dots, h(n)] \quad (1)$$

$$h(n) = Re(h(n)) + jIm(h(n)) \quad (2)$$

식(1)에서 $h(n)$ 은 n 번째 부반송파의 CSI 데이터를 의미하며, 이는 식(2)와 같이 실수부와 허수부로 구성되는 복소수 형태로 표현될 수 있다.

CSI 분석 서버는 CSI 데이터를 처리 및 분석하여 HAR 결과를 도출하고, 이를 활용하여 LLM 기반 피드백 생성을 수행하는 핵심 구성요소이다. 구체적으로, CSI 분석 서버는 데이터 전처리기, HAR 분석기, 피드백 생성기로 구성되는 SW 모듈을 포함한다. CSI 캡처기로부터 CSI 데이터를 전달받으면, 데이터 전처리기는 수신된 CSI 데이터에서 파일럿, 가드밴드, DC 성분 등 불필요한 OFDM 성분을 제거하고, 진폭을 추출한다. 이후, HAR 분석기에 탑재된 딥러닝 모델의 입력 형태를 고려하여, 전처리 된 데이터를 이미지 형태로 변환한다.

HAR 분석기는 변환된 이미지를 입력으로 받아 사용자의 행동을 추정한다. 이를 위해, [Fig. 2]와 같이 특징 추출(Feature Extraction) 및 분류(Classification) 단계로 구성된 Convolutional Neural Network(CNN) 기반 모델을 활용한다. 특징 추출 단계에서는 다수의 Convolution Layer 및 Pooling Layer를 통해 입력 이미지로부터 유의미한 특징이 추출된다. 분류 단계에서는 Flatten Layer, Dense Layer, Dropout Layer를 통해 추출된 특징을 기반으로 최종 행동을 분류한다.



[Fig. 2] CNN-Based Activity Classification Model

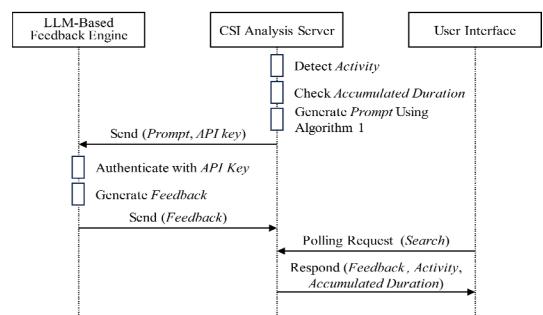
피드백 생성기는 HAR 분석기로부터 전달된 행동 분류 결과를 바탕으로, LLM을 활용하여 사용자 맞춤형 피드백을 생성한다. 이를 위해, 행동 분류 결과 및 측정 시점 등 상황정보를 포함하는 프롬프트를 구성하고, 이를 외부의 LLM 기반 피드백 엔진에 전달한다. 피드백 엔진은 입력된 프롬프트를 분석하여 언어 기반 피드백을 생성한다. 생성된 결과는 웹 기반 애플리케이션 형태의 사용자 인터페이스에 전달되어 사용자에게 제공된다.

본 논문은 HAR 시스템에 LLM을 통합하여 사용자 친화적인 피드백을 제공하는 데 중점을 둔다. 이에 따라, LLM 기반 피드백 제공 절차의 구체적인 과정은 3장에서 상세히 기술한다.

3. LLM 기반 피드백 제공 절차

[Fig. 3]은 LLM 기반 피드백 제공 절차의 전반적인 과정을 보여준다. 본 절차는 CSI 분석 서버가 HAR 분석기를 통해 행동 상태를 분류한 이후 시작된다.

행동 상태가 분류된 이후, CSI 분석 서버는 행동 상태와 지속 시간 정보를 기반으로 사용자 맞춤형 피드백 생성을 위한 프롬프트를 구성한다. 구체적으로, CSI 분석 서버의 피드백 생성기는 행동 분류를 완료할 때마다 해당 행동이 얼마나 지속되었는지 확인하고, 행동 상태와 지속 시간을 고려하여 프롬프트를 생성한다.



[Fig. 3] Sequence Diagram of Feedback Provision

Algorithm 1. Prompt Generation Procedure

INPUT: S, M

OUTPUT: *Prompt*

```

1: IF  $M \geq T$  and  $(M \bmod T) == 0$  THEN
2: IF  $S == "Sitting"$  THEN
3:   prompt  $\leftarrow$  "The user has been sitting for  $M$  minutes. Provide a brief stretching guide in three sentences."
4: ELSEIF  $S == "Standing"$  THEN
5:   prompt  $\leftarrow$  "User has been standing for  $M$  minutes. Provide a leg health guide in three sentences."
6: ELSEIF  $S == "Walking"$  THEN
7:   prompt  $\leftarrow$  "User has been walking for  $M$  minutes. Provide a walking-related health guide in three sentences."
8: ENDIF
9: ENDIF
10: RETURN Prompt

```

Algorithm 1은 프롬프트 생성 절차를 자세히 보여준다. 알고리즘에서, 행동의 종류는 Sitting, Standing, Walking으로 가정했다. S 와 M 은 행동 상태 및 지속 시간을 각각 나타내고, T 는 피드백 생성 간격을 의미한다. 특정 행동 상태에 대한 프롬프트는 M 이 T 보다 길어지는 시점에 처음으로 생성되며, T 간격마다 추가로 생성된다. 즉, 동일한 행동이 지속되는 경우, CSI 분석 서버는 T 간격마다 프롬프트를 갱신하고, 이를 LLM-기반 피드백 엔진으로 전달한다.

CSI 분석 서버는 LLM-기반 피드백 엔진을 통해 행동 상태 및 지속 시간에 따라 사용자에게 맞춤형 피드백을 제공해야 하며, 이때 피드백의 형태와 내용은 사용자가 원하는 조건에 부합해야 한다. 이를 위해, 알고리즘에서는 다음의 규칙을 고려하여 행동별 프롬프트를 구성한다.

- **Rule 1:** 행동 상태와 지속 시간을 모두 포함하여, 현재 상황을 정확히 인지하게 한다.
- **Rule 2:** 행동 상태를 고려한 구체적인 요구사항을 포함하여, 사용자 맞춤형 피드백을 제공받을 수 있게 한다.
- **Rule 3:** 제공받을 피드백의 길이를 포함하여, 피드백의 가독성을 높인다.

알고리즘에서, $S == "Sitting"$ 인 경우, "The user has been sitting for M minutes"는 Rule 1, "Provide a brief stretching guide"는 Rule 2, "in three sentences."는 Rule 3에 해당한다.

프롬프트가 생성되면, CSI 분석 서버는 해당 프롬프트와 API 통신에 필요한 인증 키(API Key)를 표준화된 텍스트 구조(JSON 기반 등)로 변환하고, 외부의 LLM-

기반 피드백 엔진으로 전달한다. 피드백 엔진은 전달받은 인증 키를 활용하여 LLM 서비스 접근 권한을 인증하고, 전달받은 프롬프트를 기반으로 최종적인 피드백을 생성한다. 생성된 피드백은 다시 CSI 분석 서버로 반환된다.

최종적으로, 사용자 인터페이스는 클라이언트-서버 팔링 모델을 기반으로 사용자에게 피드백을 전달한다. 사용자 인터페이스는 고정된 주기로 CSI 분석 서버의 피드백 상태 조회 앤드포인트에 조회 요청을 보낸다. 서버가 이 요청을 받으면 최신 피드백과, 현재 행동 상태, 누적 지속 시간을 포함하는 JSON 파일을 생성하여 반환한다. 사용자 인터페이스는 이 데이터를 수신하는 즉시 사용자 화면에 표시하여 알림을 제공한다.

4. 시스템 구현 및 동작 검증

본 장에서는 제안 시스템의 주요 구성요소인 신호 발생기, CSI 캡처기, CSI 분석 서버, 사용자 인터페이스와 CSI 분석 서버와 LLM-기반 피드백 엔진 간 연동 기능의 구현 절차 및 결과에 관해 기술한다.

신호 발생기는 TP-Link TL-WR940N Plus에 OpenWrt를 적용하여 구성했다. OpenWrt를 통해 IEEE 802.11n 모드, 채널, 송신 파라미터 등을 세밀하게 설정하여 OFDM 신호가 안정적으로 송출되는 송신 환경을 구축했다.

CSI 캡처기는 Raspberry Pi 4B와 CSI 캡처용 오픈소스 라이브러리 Nexmon을 사용하여 구현했다 [14, 15]. Nexmon을 통해 무선 칩셋을 모니터 모드로 동작시키고, 캡처된 패킷에서 CSI를 추출하여 pcap 파일로 저장하도록 구성했다. 캡처기에서 수집된 파일은 분석 서버로 전송되며, 이후 전처리를 위해 통합 저장된다. [Fig. 4(a)] 및 [Fig. 4(b)]는 구현된 신호 발생기 및 CSI 캡처기의 하드웨어를 각각 보여준다.



(a) Signal Generator
(TP-Link TL-WR940N)

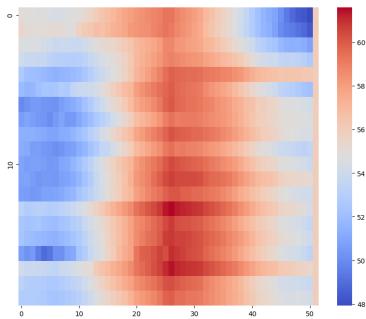


(b) CSI Capture Device
(Raspberry Pi4 B)

[Fig. 4] Signal Generator and CSI Capture Device

CSI 분석 서버는 데이터 전처리기, HAR 분석기, 피드백 생성기로 구성되는 소프트웨어 모듈 집합으로 구현했다. 먼저, 데이터 전처리기는 Python 환경에서 동작하도록 설계하였으며, pcap 파일의 Payload에서 CSI를 추출해 복소수 형태로 변환하는 기능을 구현했다. IEEE 802.11n 표준의 20MHz 대역폭은 총 64개의 서브캐리어로 구성되나, 본 연구에서는 행동 인식의 정확도를 높이기 위해 불필요 성분을 제거했다. 구체적으로 좌·우 가드 밴드 7개, DC 성분 1개, 파일럿 4개를 포함한 총 12개의 서브캐리어를 제거했으며, 최종적으로 유효한 52개 서브캐리어의 진폭을 추출하여, 하나의 CSI 데이터를 구성했다.

이후, CSI 데이터의 시계열적 특성을 반영하고자 20개의 CSI 데이터를 하나의 그룹으로 군집화 하여 히트맵 이미지로 변환했다. [Fig. 5]는 히트맵 이미지를 보여주며, X축은 52개의 서브캐리어 인덱스를 Y축은 20개의 CSI 데이터 집합 인덱스를 나타낸다.



[Fig. 5] Heatmap Image

다음으로, HAR 분석기는 생성된 히트맵을 입력으로 받아 사전에 학습된 CNN 모델을 통해 사용자의 행동 상태를 도출하도록 구현했다. 구체적으로, 훈련용 데이터셋 구축시 히트맵 이미지의 파일명에 각 행동 클래스를 직접 명시해 이를 정답 레이블로 지정하였다. 파일명을 통해 클래스가 분류된 해당 데이터셋으로 TensorFlow, Keras 등 Python 라이브러리를 활용하여 CNN 모델을 구현했다. 구축된 모델은 히트맵 이미지 특징을 기반으로 사용자의 Sitting, Standing, Walking 상태를 분류한다.

마지막으로, 피드백 생성기는 Flask 메인 프로세스의 지연을 방지하기 위해 비동기 스레드 기반 구조로 동작하도록 구현했다. HAR 분석기는 새로운 행동 상태를 감지하면, 분류 결과와 지속 시간 정보를 전달받아 프롬프트를 구성하고, 이를 별도의 백그라운드 스레드에서

Gemini API(즉, LLM 기반 피드백 엔진)로 전송한다. Gemini API가 생성한 피드백은 CSI 분석 서버로 반환되며, 이는 사용자 인터페이스로 전달된다.

웹 기반 사용자 인터페이스는 Flask의 /status, /weekly_chart 등의 엔드포인트를 통해 현재 행동 상태, 누적 지속 시간, 행동별 피드백을 실시간으로 시각화하여 제공한다. 구현된 사용자 인터페이스는 각 행동 상태(Sitting, Standing, Walking)에 대해 서로 다른 피드백 결과를 제공하며, 이는 [Fig. 6]~[Fig. 8]에서 보여준다.



[Fig. 6] User Interface: Sitting



[Fig. 7] User Interface: Standing



[Fig. 8] User Interface: Walking

제안 시스템의 실현 가능성 평가하기 위해, 실제 실내 환경에 송수신 하드웨어를 배치하고 Sitting, Standing, Walking 행동을 반복적으로 수행하여 실측 CSI 데이터를 수집하였다. 이후, 실험을 통해 수집된 CSI 데이터를 기반으로 행동을 실시간으로 추론하고, 추론 결과를 입력으로 하여 LLM 기반 피드백을 생성하는 전체 절차를 확인하였다. 실험 결과를 통해, CSI 기반 HAR과 LLM

기반 피드백 생성이 실시간으로 연동됨을 확인하였다. 즉, 실제 운용 환경에서의 실험적 구현을 통해 CSI 기반 행동 추론부터 LLM 연동 피드백 생성 및 제공까지의 전체 절차가 안정적으로 수행됨을 입증하였으며, 이를 통해 제안 시스템의 실질적 적용 가능성을 검증하였다.

5. Conclusion

본 논문은 CSI 기반의 HAR 시스템과 LLM을 통합하여 사용자 맞춤형 피드백을 실시간으로 제공하는 HAR-LLM 연동 시스템을 제안한다. 이를 위해 제안 시스템은 사용자의 행동 상태와 지속 시간을 기반으로 프롬프트를 구성하며, 행동 상태 정보, 요구사항, 피드백 길이를 반영하여 LLM 출력의 일관성과 정확성을 확보하도록 설계하였다. 시스템의 실효성을 검증하고자, 신호 발생기, CSI 캡처기, CSI 분석 서버, 사용자 인터페이스, 외부 LLM 기반 피드백 엔진으로 구성된 전체 파이프라인을 구현하였다. 구현 결과, CSI 전처리 및 히트맵 생성, CNN 기반 행동 인식, 프롬프트 생성, LLM 기반 자연어 피드백 제공에 이르는 모든 절차가 실제 운용 환경에서 안정적으로 동작함을 확인하였다. 이를 통해, 제안 시스템은 기존 HAR 시스템의 한계를 극복하고, 실제 환경에서도 활용 가능한 상황 맞춤형 피드백 제공 플랫폼으로서의 실질적인 가능성을 검증하였다.

REFERENCES

- [1] M.Kaseris, I.Kostavelis, and S.Malassiotis, "A comprehensive survey on deep learning methods in human activity recognition," *Mach. Learn. Knowl. Extr.*, Vol. 6, No. 2, pp. 842-876, 2024.
- [2] F.Serpush, M.B.Menhaj, B.Masoumi, and B.Karasfi, "Wearable Sensor-Based Human Activity Recognition in the Smart Healthcare System," *Comput. Intell. Neurosci.*, vol.2022, no.24, pp.1-12, 2022.
- [3] P.F.Moshiri, R.Shahbazian, M.Nabati, and S.A.Ghorashi, "A CSI-Based Human Activity Recognition Using Deep Learning," *Sensors*, Vol. 21, No. 21, pp. 7225, 2021.
- [4] A.Pantelopoulos and N.G.Bourbakis, "A Survey on Wearable Sensor-Based Systems for Health Monitoring and Prognosis" *IEEE Trans. Syst. Man Cybern. Part C-Appl. Rev.*, vol. 40, no. 1, pp. 1-12, Jan. 2010.
- [5] Z.Wang, B.Guo, Z.Yu and X.Zhou, "Wi-Fi CSI-Based Behavior Recognition: From Signals and Actions to Activities," *IEEE Commun. Mag.*, vol. 56, no. 5, pp. 109-115, May 2018.
- [6] A.Zhuravchak, O.Kapshii, and E.Pournaras, "Human Activity Recognition based on Wi-Fi CSI Data -A Deep Neural Network Approach," *Procedia Comput. Sci.*, Vol. 198, pp. 59-66, 2022.
- [7] S.Yousefi, H.Narui, S.Dayal, S.Ermon and S.Valaee, "A Survey on Behavior Recognition Using WiFi Channel State Information," *IEEE Commun. Mag.*, vol. 55, no. 10, pp. 98-104, Oct. 2017.
- [8] R.Alazrai, M.Hababeh, B.A.Alsaify, M.Z.Ali and M.I.Daoud, "An End-to-End Deep Learning Framework for Recognizing Human-to-Human Interactions Using Wi-Fi Signals," *IEEE Access*, vol. 8, pp. 197695-197710, 2020, doi: 10.1109/ACCESS.2020.3034849.
- [9] M.N.Shoumi and S.Inoue, "Leveraging the Large Language Model for Activity Recognition: A Comprehensive Review," *Int. J. Act. Behav. Comput.*, vol. 2024, no. 2, pp. 1-27, 2024.
- [10] N.Kashyap, M.S.Bedmutha, P.Chaudhary, B.Wood, W.Pratt, J.Sabin, A.Hartzler, and N.Weibel, "Towards Enhanced Human Activity Recognition through Natural Language Generation and Pose Estimation," arXiv preprint arXiv:2312.06965, 2023.
- [11] M.Dong, H.Huang, and L.Cao, "Can LLMs Serve As Time Series Anomaly Detectors?", arXiv preprint arXiv:2408.03475, 2024.
- [12] T.An, Y.Zhou, H.Zou, and J.Yang, "IoT-LLM: Enhancing Real-World IoT Task Reasoning with Large Language Models," arXiv preprint arXiv:2410.02429, 2025.
- [13] Z.Li, S.Deldari, L.Chen, H.Xue, and F.D.Salim, "SensorLLM: Aligning Large Language Models with Motion Sensors for Human Activity Recognition," arXiv preprint arXiv:2410.10624, 2025
- [14] Nexmon [Online]. Available: <https://nexmon.org>
- [15] Teach, Learn, and Make with Raspberry Pi Foundation [Online]. Available: <https://www.raspberrypi.org>

박 혜 진(Hye-Jin Park)



[준회원]

- 2023년 3월 ~ 현재 : 한림대학교 소프트웨어학부 학사과정

〈관심분야〉

사물인터넷, 무선센서네트워크, 임베디드시스템, 머신러닝

강 인 혁(Inhyeok Kang)



[정회원]

- 2023년 8월 : 한림대학교 응합소프트웨어학과 (공학사)
- 2025년 8월 : 한림대학교 응합소프트웨어학과 (공학석사)
- 2025년 9월 ~ 현재 : 한림대학교 응합소프트웨어학과 박사과정

〈관심분야〉

사물인터넷, 무선센서네트워크, 해상무선통신, 머신러닝, 차량 네트워크, 블록체인

이 솔 비(Sol-Bee Lee)



[정회원]

- 2018년 2월 : 한림대학교 응합소프트웨어학과 (공학사)
- 2024년 2월 : 한림대학교 응합소프트웨어학과 (공학박사)
- 2024년 3월 ~ 현재 : 한림대학교 스마트컴퓨팅연구소 연구교수

〈관심분야〉

사물인터넷, 무선센서네트워크, 무선전력전송, 해상무선통신, 차량 네트워크, 머신러닝, 블록체인

권 정 혁(Jung-Hyok Kwon)



[정회원]

- 2010년 2월 : 숭실대학교 정보통신전자공학부 (공학사)
- 2012년 8월 : 고려대학교 전기전자전파공학과 (공학석사)
- 2019년 2월 : 한림대학교 응합소프트웨어학과 (공학박사)

- 2013년 4월 ~ 2015년 6월 : LIG넥스원 SW연구센터 선임연구원

- 2019년 3월 ~ 현재 : 한림대학교 스마트컴퓨팅연구소 연구교수

〈관심분야〉

사물인터넷, 무선센서네트워크, 무선전력전송, 해상무선통신, 차량 네트워크, 머신러닝, 블록체인

김 의 직(Eui-Jik Kim)



[정회원]

- 2004년 2월 : 고려대학교 전기전자전파공학부 (공학사)
- 2006년 2월 : 고려대학교 전자컴퓨터공학과 (공학석사)
- 2013년 2월 : 고려대학교 전기전자전파공학과 (공학박사)

- 2006년 2월 ~ 2009년 7월 : 삼성전자 DMC연구소 선임연구원

- 2009년 8월 ~ 2013년 8월 : KT 응합기술원 선임연구원

- 2013년 9월 ~ 현재 : 한림대학교 소프트웨어학부 교수

〈관심분야〉

사물인터넷, 무선센서네트워크, 무선전력전송, 해상무선통신, 차량 네트워크, 머신러닝, 블록체인